Bagian A: Analisis Konseptual (Bobot: 20%)

Jawab kelima pertanyaan berikut secara ringkas, padat, dan terstruktur (100–150 kata per nomor). Cantumkan rujukan nomor slide yang relevan serta sitasi literatur ilmiah pendukung jika merujuk sumber eksternal.

1. Efek Regularisasi pada Batch Normalization (Slide 6–8)
   Slide 8 menyebutkan bahwa Batch Normalization "acts like mild regularization" dan "often eliminates the need for Dropout".
   - Jelaskan mekanisme statistik mini-batch yang menimbulkan efek regularisasi tersebut.
   - Uraikan kondisi atau skenario spesifik ketika asumsi "menghilangkan Dropout" ini tidak lagi berlaku atau justru dapat memicu instabilitas pelatihan.

Batch Normalization (BN) menghitung statistik *mean* dan *variance* dari *mini-batch* selama pelatihan. Variasi stokastik acak (*stochastic noise*) dari komposisi *mini-batch* ini menyuntikkan *noise* aditif pada aktivasi, berfungsi sebagai regularisasi ringan yang mengurangi *overfitting*.. Efek regularisasi BN sangat bergantung pada ukuran batch, di mana batch yang sangat kecil dapat menurunkan stabilitas estimasi statistik dan mengubah kekuatan regularisasinya.

Pernyataan bahwa BN "menghilangkan kebutuhan Dropout" hanya berlaku bersyarat (*"in some cases"*). Kombinasi BN dan Dropout justru dapat memicu instabilitas akibat *variance shift*, yaitu ketidakcocokan akumulasi varians saat transisi dari pelatihan ke inferensi. Oleh karena itu, Dropout tetap dapat diperlukan pada arsitektur tertentu atau dataset terbatas.

2. Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)
   Mengapa penambahan kedalaman lapisan pada plain CNN (tanpa sambungan residual) justru menurunkan akurasi pelatihan (degradation problem), padahal secara teoritis representasi model yang lebih dalam minimal dapat menyamai model dangkal via fungsi identitas (identity mapping)?
   - Jelaskan bagaimana skip connection mengubah formulasi aliran gradien saat propagasi balik (backpropagation).
   - Hubungkan mekanisme tersebut dengan mitigasi fenomena vanishing gradient yang telah dibahas pada Sesi 02.

Pada plain CNN, penambahan kedalaman lapisan memicu masalah degradasi (degradation problem) akibat optimisasi gradien yang semakin sulit (vanishing/exploding gradient) saat propagasi balik (backpropagation) melewati banyak perkalian matriks berturut-turut.

ResNet memitigasi hal ini melalui skip connection dengan merumuskan pemetaan $y = F(x) + x$. Saat backpropagation, turunan loss L terhadap input x diformulasikan secara

matematis sebagai:

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \cdot \left(\frac{\partial F(x)}{\partial x} + I \right)$$

Keberadaan matriks identitas $+ I$ menjamin aliran gradien langsung (gradient highway) menuju lapisan awal tanpa halangan. Mekanisme ini memastikan gradien tidak pernah bernilai nol meskipun $\frac{\partial F(x)}{\partial x} \approx 0$, sehingga efektif mengatasi vanishing gradient

3. Feature Extraction vs. Fine-Tuning (Slide 14–16)
   Bandingkan pendekatan Feature Extraction (membekukan backbone) dengan FineTuning (membuka sebagian atau seluruh lapisan) ditinjau dari empat dimensi:
   - Jumlah parameter yang diperbarui (trainable parameters).
   - Kebutuhan volume data latih.
   - Beban komputasi dan memori per epoch.
   - Risiko rusaknya fitur representasi bawaan (destructive gradient updates).
     Sintesiskan kriteria praktis kapan masing-masing pendekatan paling tepat dipilih.

Perbandingan kedua pendekatan berdasarkan empat dimensi utama :

- Jumlah Parameter Trainable: Feature Extraction hanya memperbarui bobot lapisan classifier/head, sedangkan Fine-Tuning memperbarui sebagian atau seluruh lapisan backbone.
- Kebutuhan Data Latih: *Feature Extraction* cocok untuk dataset kecil, sementara *Fine-Tuning* membutuhkan volume data lebih besar untuk mencegah *overfitting*.
- Beban Komputasi & Memori: *Feature Extraction* jauh lebih hemat sumber daya per *epoch* karena tidak menghitung gradien pada *backbone* .
- Risiko Destructive Gradient: *Fine-Tuning* berisiko merusak representasi fitur bawaan jika *learning rate* terlalu tinggi, sedangkan *Feature Extraction* bebas dari risiko ini.

Kriteria Praktis: Pilih Feature Extraction jika dataset kecil dan domain mirip dengan data pretrained. Pilih Fine-Tuning jika dataset besar atau domain target berbeda signifikan dari data pretrained

4. Kaidah Penerapan Data Augmentation (Slide 20, 21, 23)
   - Jelaskan pertimbangan metodologis mengapa pipeline data augmentation hanya diaktifkan pada train set dan harus dinonaktifkan pada validation/test set.

- Berikan satu contoh teknik transformasi citra yang tidak layak digunakan untuk klasifikasi ras hewan peliharaan (pet breeds), dan jelaskan argumentasi ketidaklayakannya berdasarkan invariansi semantik label.

Data augmentation hanya diaktifkan pada *train set* untuk memperkaya variasi sampel dan melatih invariansi fitur. Pada *validation* dan *test set*, augmentasi harus dinonaktifkan agar evaluasi menggunakan data asli (*ground truth*). Menerapkan augmentasi pada set evaluasi berisiko menyebabkan *data leakage* dan menghasilkan estimasi performa yang bias serta tidak objektif.

Untuk klasifikasi ras hewan (*fine-grained recognition*), transformasi yang merusak atau menghapus petunjuk visual halus (*discriminative visual cues*), seperti pemotongan ekstrem atau perubahan warna acak, dapat merusak pembedaan antar kelas. Tingkat ekstremitas augmentasi warna harus dievaluasi dengan hati-hati agar tidak menghilangkan informasi semantik spesifik ras, bukan langsung dinyatakan selalu tidak layak tanpa pengujian.

5. Mitigasi Catastrophic Forgetting (Slide 28–29)
   Slide 28 mengingatkan potensi terjadinya catastrophic forgetting apabila proses adaptasi model berlangsung terlalu agresif.
   - Uraikan bagaimana fenomena hilangnya representasi bawaan tersebut terjadi.
   - Jelaskan dua strategi mitigasi konkret (misalnya differential learning rate, gradual unfreezing, atau linear warmup) beserta alasan teoritis mengapa strategi tersebut efektif.

Catastrophic forgetting terjadi ketika pembaruan gradien yang terlalu agresif (destructive gradient updates) dari tugas baru menimpa (overwrite) bobot dan representasi fitur generik yang telah dipelajari selama pre-training. Akibatnya, model kehilangan kapabilitas representasi dasarnya.

Dua strategi mitigasi yang efektif:

1. **Gradual Unfreezing:** Membekukan seluruh *backbone* dan melatih *classifier* terlebih dahulu, lalu membuka lapisan *backbone* secara bertahap dari atas ke bawah untuk membatasi lonjakan gradien awal.
2. **Differential Learning Rates:** Menerapkan *learning rate* lebih kecil pada lapisan awal dan lebih besar pada lapisan atas/*head*. Strategi ini menjaga stabilitas fitur tingkat rendah yang universal.

Referensi :
Brenner, M. (2019). *Deep residual learning*. Semantic Scholar.
https://www.semanticscholar.org/paper/ed61ad029ab491852b5bc1862c07b5b76fbbdd2b

Chronopoulou, A., Baziotis, C., & Potamianos, A. (2019). An embarrassingly simple approach for transfer learning from pretrained language models. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*, 2089–2095. https://doi.org/10.18653/v1/N19-1213

Howard, J., & Ruder, S. (2018). Universal language model fine-tuning for text classification. *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*, 328–339. https://doi.org/10.18653/v1/P18-1031

Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. *International Conference on Machine Learning (ICML)*, 448–456. https://www.semanticscholar.org/paper/995c5f5e62614fcb4d2796ad2faab969da51713e

Li, X., Chen, S., Hu, X.-L., & Yang, J. (2018). Understanding the disharmony between dropout and batch normalization by variance shift. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2682–2690. https://doi.org/10.1109/CVPR.2019.00279

Luo, P., Wang, X.-J., Shao, W., & Peng, Z. (2018). Understanding regularization in batch normalization. *arXiv preprint arXiv:1809.00846*. https://www.semanticscholar.org/paper/d3fe13e0ff2f09773c02e12a2a287f8baa58ec83

Pu, Y., Han, Y., Wang, Y., Feng, J., Deng, C., & Huang, G. (2023). Fine-grained recognition with learnable semantic data augmentation. *IEEE Transactions on Image Processing*, 33, 1548–1560. https://doi.org/10.1109/TIP.2024.3364500

Puvanendran, R., Sayakkara, A., Jeyarathna, T., & Ragel, R. (2026). Benchmarking data leakage and generalization in audio classification: An empirical analysis. *IEEE International Conference on Industrial and Information Systems (ICIIS)*. https://doi.org/10.1109/ICIIS69028.2026.11450559

Soekhoe, D., Putten, P. V. D., & Plaat, A. (2016). On the impact of data set size in transfer learning using deep neural networks. *International Conference on Discovery Science*, 50–65. https://doi.org/10.1007/978-3-319-46349-0_5

Yong, H., Huang, J., Meng, D., Hua, X., & Zhang, L. (2020). Momentum batch normalization for deep learning with small batch size. *European Conference on Computer Vision (ECCV)*, 224–240. https://doi.org/10.1007/978-3-030-58610-2_14