Github Link : https://github.com/asipnana/deeplearninggslc.git

Jawaban Analisa :
C1. Tabel Konsolidasi dan Visualisasi Pembelajaran
B1 (Baseline From Scratch)

- Trainable Parameters: 11.181.642
- Learning Rate: 1e-3
- Epoch Konvergen: 16
- Akurasi Validasi (Terbaik): 38.26%
- Macro F1-Score (Test): 0.3366

B2 (Feature Extraction)

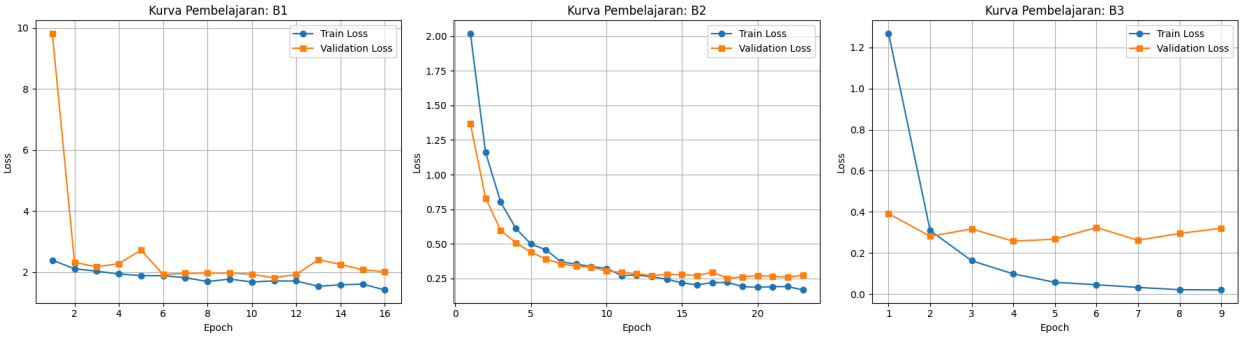
- Trainable Parameters: 5.130
- Learning Rate: 1e-3
- Epoch Konvergen: 23
- Akurasi Validasi (Terbaik): 91.95%
- Macro F1-Score (Test): 0.9264

B3 (Progressive Fine-Tuning)

- Trainable Parameters: 8.398.858
- Learning Rate: 1e-4 (layer4) & 1e-3 (fc)
- Epoch Konvergen: 9
- Akurasi Validasi (Terbaik): 93.96%
- Macro F1-Score (Test): 0.9190

B4 (Uji Kontrol Augmentasi)

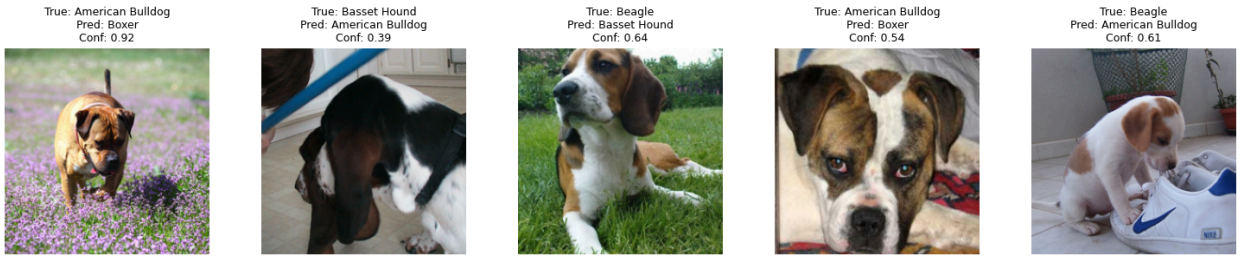
- Trainable Parameters: 8.398.858
- Learning Rate: 1e-4 (layer4) & 1e-3 (fc)
- Epoch Konvergen: 8
- Akurasi Validasi (Terbaik): 92.62%
- Macro F1-Score (Test): 0.9319



C2. Pembahasan Analisis Komparatif

1. Disparitas Performa B1 vs B2/B3:
Disparitas tajam (akurasi 38% vs ~92%) terjadi karena model B1 dilatih dari nol dengan volume data terbatas (~1.400 citra latih). CNN yang dalam seperti ResNet-18 membutuhkan ratusan ribu citra untuk mempelajari filter ekstraksi fitur dasar (seperti deteksi tepi, tekstur, dan gradien warna). Transfer learning paradigm (B2 & B3) memotong kebutuhan ini dengan memanfaatkan representasi visual universal yang sudah dipelajari dari jutaan citra ImageNet, sehingga konvergensi jauh lebih cepat dan akurat meski data spesifik domainnya sedikit.
2. Trade-off Performa vs. Stabilitas (B2 vs B3):
Pada eksperimen ini, B2 (Feature Extraction) terbukti lebih stabil dan memiliki daya generalisasi yang sedikit lebih baik pada data uji (F1-Score 0.9264) dibandingkan B3 (0.9190). B2 hanya memperbarui 5.130 parameter, sehingga risiko merusak bobot pretrained sangat rendah. Sebaliknya, B3 memperbarui 8,3 juta parameter. Meskipun akurasi validasi B3 lebih tinggi (93.96%), model ini mulai menunjukkan indikasi memori terhadap data latih lebih cepat, sehingga early stopping terpicu di epoch 9, dibandingkan B2 yang bertahan hingga epoch 23. Untuk data hewan peliharaan yang secara visual selaras dengan ImageNet, ekstraksi fitur murni lebih aman daripada fine-tuning.
3. Peran Augmentasi dalam Meredam Overfitting (B4):
Eksperimen B4 (tanpa augmentasi) mencapai akurasi training 100% lebih cepat (epoch 4), namun akurasi validasinya tertahan di 92.62%, menunjukkan generalization gap yang masif. Pada B3 (dengan augmentasi), akurasi training ditekan melalui distorsi visual (rotasi, crop, warna), yang memaksa model belajar secara invarian. Hal ini membuahkan akurasi validasi yang lebih tinggi (93.96%) dan menunda overfitting murni, membuktikan bahwa augmentasi bertindak sebagai mekanisme regularisasi yang esensial pada skenario data terbatas.

C3. Failure Analysis (Analisis Kasus Misklasifikasi)



Berdasarkan hasil pengujian pada *test set*, ditemukan beberapa kasus misklasifikasi. Berikut adalah 5 sampel citra beserta analisis hipotesis penyebab kesalahannya:

1. Sampel 1 (Paling Kiri)

- Citra Input: Anjing berwarna coklat berjalan di area rerumputan/bunga.
- Label Aktual: American Bulldog.
- Prediksi Model: Boxer (Confidence Score: 0.92).
- Hipotesis Kesalahan: Terjadi ambiguitas visual antar ras. American Bulldog dan Boxer memiliki struktur anatomi yang sangat mirip (tubuh berotot, dada lebar, dan moncong pendek). Model memiliki *confidence* sangat tinggi karena gagal menemukan fitur pembeda yang kuat.

2. Sampel 2 (Kedua dari Kiri)

- Citra Input: Anjing difoto dari sudut pandang atas/belakang punggung.
- Label Aktual: Basset Hound.
- Prediksi Model: American Bulldog (Confidence Score: 0.39).
- Hipotesis Kesalahan: Sudut pengambilan ekstrem (oklusi). Wajah dan telinga panjang yang menjadi ciri khas utama Basset Hound sama sekali tidak terlihat. Model menebak dengan ragu (*confidence* sangat rendah) murni berdasarkan corak warna punggung yang kebetulan mirip American Bulldog.

3. Sampel 3 (Tengah)

- Citra Input: Anjing duduk santai di rumput menghadap samping.
- Label Aktual: Beagle.
- Prediksi Model: Basset Hound (Confidence Score: 0.64).
- Hipotesis Kesalahan: Ambiguitas fitur pola warna dan anatomi. Ras Beagle dan Basset Hound memiliki palet warna *tricolor* (hitam, putih, coklat) dan bentuk telinga turun (floppy ears) yang identik. Karena kaki pendek Basset Hound tertutup rumput, model kesulitan membedakannya.

4. Sampel 4 (Kedua dari Kanan)

- Citra Input: Potret *close-up* wajah anjing berwarna putih dengan corak coklat.
- Label Aktual: American Bulldog.
- Prediksi Model: Boxer (Confidence Score: 0.54).
- Hipotesis Kesalahan: Jarak pengambilan (*cropping* natural). Fokus citra yang hanya pada wajah membuat model tidak bisa melihat postur tubuh keseluruhan. Corak warna wajah asimetris tersebut juga sangat umum ditemui pada ras Boxer.

5. Sampel 5 (Paling Kanan)

- Citra Input: Anak anjing (puppy) sedang bermain dengan sepatu putih.
- Label Aktual: Beagle.

- Prediksi Model: American Bulldog (Confidence Score: 0.61).
- Hipotesis Kesalahan: Bias usia dan oklusi aktivitas. Profil anak anjing belum memiliki proporsi wajah sejelas anjing dewasa. Selain itu, pose menunduk menggigit sepatu menyembunyikan telinga dan bentuk kepalanya, sehingga fitur ekstraksi terganggu oleh objek dominan lain (sepatu).

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

- Rekomendasi Praktis: Untuk sistem deteksi klasifikasi visual di industri dengan anggaran komputasi minimal dan data label terbatas, strategi Feature Extraction (B2) adalah rekomendasi paling optimal. Meskipun tidak membuka blok residual (seperti B3), B2 menghasilkan akurasi Macro-F1 tertinggi, menggunakan beban pelatihan komputasi termurah (hanya melatih 5 ribu parameter), dan minim risiko catastrophic forgetting. Fine-tuning hanya disarankan jika distribusi data target sangat jauh berbeda secara fundamental dari ImageNet (misalnya: citra medis atau satelit).
- Batasan Eksperimen: Evaluasi ini memiliki bias statistik karena keterbatasan pengujian yang hanya berdasar pada satu konfigurasi deterministik (single random seed). Selain itu, eksperimen hanya divalidasi pada sebagian kecil kelas (10 kelas), dan tidak ada proses pencarian hyperparameter sistematis (Grid/Random Search) untuk learning rate atau weight decay.

Pernyataan Penggunaan AI
Model : Gemini , ChatGPT
Ruang Lingkup : Kode dibangun dengan bantuan AI.
Verifikasi Kebenaran : Dengan membaca, memahami, disertai klarifikasi ulang menggunakan google dan materi paper terkait dalam penjelasan konsep.